# Predicción del éxito académico en educación superior

Proyecto final de Aprendizaje Automático

Pilar Pérez Hernández
2º IMAT B, ICAI – Universidad Pontificia Comillas
Curso 2025/2026

**Abstract**

En este proyecto trabajo con un dataset de 4.424 estudiantes de educación superior y planteo tres modelos complementarios sobre los mismos datos: un clasificador multiclase para la situación final del estudiante (abandono, matriculado o graduado), un regresor de la nota media del segundo semestre que evita usar variables contemporáneas al target, y un clustering descriptivo para sacar perfiles de alumnado. El mejor clasificador es un Gradient Boosting que llega a F1 macro de 0,69 en test, frente al 0,22 del baseline trivial; la clase "matriculado" es donde más cuesta acertar. En regresión bajo el RMSE a 2,69 desde el 5,20 del baseline, una reducción del 48%. El clustering sobre PCA al 90% me devuelve tres perfiles bastante estables (silueta 0,39, ARI frente a Ward 0,89, ARI bootstrap medio 0,91) que se interpretan como "riesgo / abandono masivo", "rendimiento medio" y "rendimiento alto con mayor edad". Lo más interesante para mí es que las variables que más pesan son las mismas en las tres tareas: aprobadas y nota media del primer semestre, nota de admisión y un par de administrativas (matrícula al día, deudor, edad). Al final discuto limitaciones, leakage, desbalanceo, estabilidad de los clusters y los riesgos éticos de aplicar este tipo de modelos a la detección de alumnado en riesgo.

## 1 Introducción y dataset

El conjunto de datos tiene 4.424 estudiantes y 37 variables, todas rellenas y sin duplicados. El target es `objetivo` con tres clases: graduado (49,9%), abandono (32,1%) y matriculado (17,9%). Las predictoras vienen organizadas en seis bloques que son los que el enunciado sugiere y que a mí me viene bien mantener para razonar el resto: demográficas (6), acceso y contexto previo (11), socioeconómicas y administrativas (4), macroeconómicas (3), rendimiento del 1.er semestre (6) y rendimiento del 2.º semestre (6).

Una facilidad que da el dataset es que las variables categóricas llegan ya con etiquetas legibles en lugar de códigos numéricos, así que `ocupacion_madre` es texto y se lee directamente. Eso ahorra un paso de recodificación pero también obliga a mirar el número de niveles de algunas variables: `curso` tiene 17 valores y `ocupacion_madre` llega a 31, lo cual va a importar cuando piense en aplicar one-hot. La hipótesis con la que entro al análisis es sencilla: si el planteamiento metodológico es coherente, las mismas variables deberían aparecer arriba en las tres tareas. Esa coincidencia, si se da, me sirve como triangulación entre clasificación, regresión y clustering.

## 2 Análisis exploratorio

Lo primero que miré fue la distribución del target. El baseline trivial que siempre predice "graduado" saca un 49,9% de accuracy y un F1 macro de solo 0,22 porque ignora a las otras dos clases. Cualquier modelo que aspire a ser útil tiene que superar esa cifra por bastante margen, y ya con eso aprendí que la accuracy iba a engañarme y que tendría que apoyarme en F1 macro.

Pasé luego a las variables numéricas. La nota de admisión se concentra entre 120 y 140 sobre 200, la nota media del 1.er semestre entre 10 y 14, y la del 2.º semestre tiene una forma rara: es *bimodal*, con un pico grande en cero (estudiantes que no se presentan o que abandonan a mitad de curso) y luego una nube continua entre 10 y 18. Esa bimodalidad terminó condicionando toda la regresión, así que la marqué desde el principio como un detalle a tener en cuenta. La edad al matricularse va de 17 a 70, con cola larga a la derecha: el 11% del alumnado supera los 30 años y, según se ve en los gráficos, los que entran más mayores abandonan bastante más.

En las correlaciones también aparecen cosas claras. Las notas medias de los dos semestres correlacionan 0,84 entre sí, y las dos por encima de 0,60 con las asignaturas aprobadas del semestre correspondiente. Es decir, el bloque de rendimiento es a la vez el más redundante y el que mejor separa las clases. En cambio las macroeconómicas (desempleo, inflación, PIB) casi no correlacionan con el rendimiento individual, $|r| < 0{,}05$ frente a `nota_media_2sem`: son contexto, pero no discriminan.

Para las categóricas usé Cramér's V con corrección de sesgo. Los valores más altos los tienen `curso` (0,28), `modo_solicitud` (0,22), `nacionalidad` (0,08) y `genero` (0,09). De las binarias, `deudor` y `matricula_al_dia` muestran diferencias muy claras por clase: los deudores abandonan casi el doble que los no deudores, y los que tienen la matrícula al día se gradúan bastante más. También miré las tasas de abandono por curso, que oscilan entre el 50% y el 15%, pero con un $n$ muy desigual (entre 12 y 766 estudiantes por curso), por lo que a los cursos pequeños hay que leerlos con cautela.

Como balance del EDA me llevo cuatro cosas que reutilizo en los notebooks siguientes. El desbalanceo es moderado, no extremo. Las variables que más separan son las de rendimiento académico, alguna administrativa (matrícula al día, deudor, beca) y la edad. La nota media del 2.º semestre es bimodal, y eso obliga a tratarla con cuidado en regresión. Y las macroeconómicas casi no aportan a nivel individual.

## 3 Preprocesado y decisiones metodológicas

Una decisión que tomé pronto y que dio bastante juego después fue trabajar con dos preprocesados distintos según el tipo de modelo. Para árboles y ensembles uso `OrdinalEncoder` sin escalado, porque los splits operan sobre valores ordenados y la escala da igual. Para los lineales, KNN, SVM y MLP, en cambio, monto un `OneHotEncoder` más `StandardScaler`: ahí sí me preocupaba meter órdenes falsos en categóricas y dejar que `asignaturas_1sem_aprobadas` dominara sobre `edad_al_matricularse` solo por su escala. Todo va envuelto en `ColumnTransformer` y `Pipeline`, así el scaler se ajusta exclusivamente con el train de cada fold de la CV y no hay fuga del test ni entre folds.

El control de leakage para la regresión es la otra decisión importante. Saco como predictoras `nota_media_2sem` (que es el target) y las cinco `asignaturas_2sem_*`, porque son contemporáneas al target: predecir con ellas sería trivial e informativamente pobre. También quito `objetivo`, ya que un graduado tiene por construcción nota del segundo semestre. Me quedo entonces con 30 predictoras de los bloques 1 a 5.

Sobre el split, parto un 80/20 estratificado en clasificación para conservar las proporciones de las tres clases en train y en test. En regresión no se estratifica (target continuo) pero sí fijo la semilla. El test no se toca hasta la evaluación final.

La métrica principal en clasificación es F1 macro: la accuracy penaliza muy poco ignorar a la minoritaria ("matriculado"), y F1 macro promedia las tres clases por igual. En regresión uso RMSE como métrica central y MAE y $R^2$ de apoyo, pero además voy a desglosar las métricas por régimen del target (ceros frente a rango continuo) para no esconder la bimodalidad detrás de una cifra única.

## 4 Tarea 1: clasificación

Empecé con un baseline amplio de ocho modelos sobre el train, evaluados con CV 5-fold estratificada: regresión logística, KNN, Naive Bayes gaussiano, árbol suelto, Random Forest, Gradient Boosting, SVM con kernel RBF y MLP. El ranking en F1 macro lo encabezan Gradient Boosting ($\approx 0{,}72$) y Random Forest ($\approx 0{,}70$). Lo que me sorprendió fue que la regresión logística aguanta muy cerca, $\approx 0{,}71$, lo que me hizo sospechar que buena parte de la señal es lineal. El árbol suelto y KNN se quedan en torno a 0,63–0,66 y Naive Bayes en 0,61.

Con la clase "matriculado" al 17,9% había sitio para probar rebalanceo, aunque el desbalanceo no es extremo. Comparé Random Forest tal cual, con `class_weight='balanced'` y con SMOTENC dentro de un pipeline de `imblearn`. Usé SMOTENC y no SMOTE clásico porque mis categóricas entran codificadas como enteros con `OrdinalEncoder`: SMOTE interpolaría entre códigos y

generaría híbridos sin sentido. Las tres estrategias quedaron dentro de una banda de $\pm 0{,}005$ en F1 macro, así que no merecía la pena complicar el pipeline y me quedé con la versión sin rebalanceo.

Para afinar hiperparámetros monté un `GridSearchCV` sobre RF y GB con una rejilla compacta (profundidad, `n_estimators`, `learning_rate`, `min_samples_split` y `min_samples_leaf`). El ganador fue Gradient Boosting con `n_estimators=400`, `learning_rate=0,05`, `max_depth=3` y `subsample=0,8`, con F1 macro CV de 0,72.

Sobre el conjunto de test el GB afinado da accuracy 0,767, F1 macro 0,693 y F1 weighted 0,758. La tabla 1 desglosa el rendimiento por clase.

**Table 1:** Informe por clase del Gradient Boosting en el conjunto de test.

| Clase | Precisión | Recall | F1 | Soporte | % acierto |
|---|---|---|---|---|---|
| Abandono | 0,832 | 0,732 | 0,779 | 284 | 73,2% |
| Matriculado | 0,504 | 0,396 | 0,444 | 159 | 39,6% |
| Graduado | 0,800 | 0,923 | 0,857 | 442 | 92,3% |
| Macro avg | 0,712 | 0,684 | 0,693 | 885 | — |
| Weighted avg | 0,757 | 0,767 | 0,758 | 885 | — |

Los aciertos se concentran en "graduado" y "matriculado" es con bastante diferencia la clase más complicada. La matriz de confusión confirma la sospecha: cuando el modelo se equivoca con un matriculado reparte sus errores casi al 50% entre "graduado" (63 de 159) y "abandono" (33 de 159). Visto en frío tiene sentido, porque los matriculados son por definición los estudiantes en trayectoria intermedia dentro del horizonte temporal del dataset, así que pueden parecerse a cualquiera de los otros dos grupos.

Las curvas ROC y Precision-Recall (one-vs-rest) cuentan la misma historia. El AUC-ROC pasa de 0,90 en abandono y graduado y se queda en 0,80 en matriculado, y las PR son aún más explícitas: matriculado tiene AP $\sim 0{,}45$ mientras que graduado roza 0,93 y abandono 0,88. Con desbalanceo moderado la PR es más informativa que la ROC. En las curvas de aprendizaje el train y la validación convergen hacia el final con un gap pequeño, lo que descarta infraajuste y deja el sobreajuste bajo control: añadir más datos probablemente aporte poco.

Para la interpretabilidad comparé Gini, permutation importance y SHAP. Las dos primeras coinciden en el top, lo cual es buena señal (si Gini se hubiese desviado mucho habría olido a sesgo de cardinalidad). Los SHAP sobre el RF afinado lo rematan: las cinco variables más influyentes en orden son `asignaturas_2sem_aprobadas`, `matricula_al_dia`, `asignaturas_1sem_aprobadas`, `nota_media_2sem` y `edad_al_matricularse`. Conviene fijarse en que las dos primeras son del 2.º semestre. El modelo predice bien, pero predice bien con información tardía: si quisiera convertir esto en un sistema de alerta temprana habría que reentrenarlo sin esas variables y la métrica bajaría.

En cuanto a los errores, se concentran en la frontera con "matriculado" y aparecen sobre todo en estudiantes con nota del 2.º semestre entre 8 y 11, justo donde las tres clases se solapan más. No detecto ningún patrón evidente por género ni por nacionalidad en los errores.

## 5 Tarea 2: regresión

La pregunta de la regresión la formulo distinto a la clasificación: quiero saber si puedo predecir `nota_media_2sem` usando solo información disponible al cierre del 1.er semestre. Excluyo las variables contemporáneas ya citadas y, sobre los 30 predictores restantes, hago el split 80/20 y una CV de 5 folds sobre train, igual que en clasificación.

El listón lo pone un `DummyRegressor` con la media: RMSE de 5,20 y $R^2$ aproximadamente cero, como cabía esperar. Esa cifra es la que cualquier modelo serio tiene que batir con margen. Comparando candidatos en CV: regresión lineal 2,69, Ridge 2,65, Lasso y ElasticNet 2,60, KNN 2,89, árbol suelto 3,02, RF 2,49 y GB 2,47. Aquí los lineales regularizados aguantan mucho mejor que en clasificación (en términos relativos), lo que refuerza la idea de que parte de la relación con `nota_media_2sem` es lineal. RF y GB ganan, pero por poco.

Afino RF y GB con `GridSearchCV` sobre rejillas en `n_estimators`, profundidad y `learning_rate`. Los dos quedan prácticamente empatados, con $\Delta$RMSE $< 0{,}01$ en CV. Selecciono por CV y no por el rendimiento en test, porque elegir por test sería contaminar la selección con información de evaluación, y el test tiene que servir solo para medir. Me quedo con Random Forest porque da menor RMSE en CV, aunque luego en test el GB sale igualado.

**Table 2:** Métricas en test (global y desglose por régimen del target).

| Régimen | $n$ | RMSE | MAE | $R^2$ |
|---|---|---|---|---|
| Global | 885 | 2,687 | 1,463 | 0,733 |
| Continuo ($y > 0$) | 712 | 2,014 | 1,178 | — |
| Cero ($y = 0$) | 173 | 4,499 | 2,636 | — |
| Baseline (Dummy) | 885 | 5,203 | 4,022 | 0,000 |

La tabla 2 resume la evaluación en test. El modelo reduce el RMSE un 48% sobre el baseline y llega a un $R^2$ global de 0,73, que parece un buen resultado. Sin embargo, el desglose por régimen cuenta una historia más matizada: en los *ceros* (estudiantes que no se presentan o que abandonan a mitad de curso) el error es *mayor*, no menor. Lo que ocurre es que el modelo los suaviza hacia la nube continua y termina prediciendo en torno a 2 o 3 cuando el valor real es 0. En el rango continuo el error absoluto sí es bajo (MAE de 1,18 sobre una escala de 0 a 20), pero el $R^2$ local sale negativo porque dentro de ese subgrupo la varianza de referencia es muy pequeña: el modelo acierta la media del rango, pero no la dispersión fina. Una arquitectura en dos etapas (primero clasificar si el estudiante llega a presentarse al 2.º semestre y después regresar la nota condicionada a presentación) sería más honesta para este target, pero se sale del alcance del proyecto y la clasificación de presentación ya la tengo, en cierta medida, en la Tarea 1.

El análisis de residuos lo confirma. El scatter real frente a predicho deja ver los dos regímenes: una nube compacta entre 10 y 18, y un grupo aparte cerca de 0 que el modelo empuja hacia arriba. Los residuos están centrados en cero sin sesgo global, pero se abren un poco en los extremos (heteroscedasticidad leve), y el histograma queda aproximadamente simétrico.

En interpretabilidad vuelven a coincidir Gini y permutation importance en el top. Las cinco variables más influyentes son `asignaturas_1sem_aprobadas` (muy por delante de las demás, con $\Delta$RMSE de 2,66 al permutar), `nota_media_1sem`, `asignaturas_1sem_evaluadas`, `curso` y `matricula_al_dia`. Las macro, las ocupaciones de los padres y la nacionalidad caen con importancia cercana a cero. SHAP dice lo intuitivo: más aprobadas y nota media alta en el 1.er semestre tiran la predicción hacia arriba; edad alta y deuda la bajan.

Los errores grandes se reparten en dos tipos. Por un lado, estudiantes que iban bien en 1.er semestre y se hunden en el 2.º (recae el rendimiento sin que ninguna predictora lo anuncie); por otro, estudiantes que iban flojos y remontan. Son cambios de trayectoria que con los predictores disponibles no se pueden anticipar y, en mi opinión, marcan el techo de lo que se puede predecir en este problema.

## 6 Tarea 3: aprendizaje no supervisado

La tercera tarea pide un subconjunto razonado de variables y por aquí tomé varias decisiones. Me quedo con 13: las ocho de rendimiento (notas medias y aprobadas/evaluadas de los dos semestres, más `nota_admision` y `edad_al_matricularse`), cuatro administrativas (`becado`, `deudor`, `matricula_al_dia`, `desplazado`) y `genero`. Dejo fuera las macro porque casi no correlacionan con el rendimiento, y `nacionalidad`, `internacional`, `estado_civil` y `necesidades_educativas_especiales` porque tienen casi toda la masa concentrada en un único valor. Sobre todo descarto las ocupaciones y cualificaciones de los padres y `curso`, porque tienen demasiados niveles y al pasarlos a one-hot inflan la dimensión hasta el punto de que los clusters acabarían girando en torno al perfil familiar o a la titulación, no a la trayectoria académica. También quito `asignaturas_*_convalidadas` y `asignaturas_*_sin_evaluacion` por varianza muy baja o solapamiento con aprobadas y evaluadas. Aquí sí incluyo las del 2.º semestre, al contrario que en regresión: como no estoy prediciendo nada y solo describo trayectorias completas,

no hay leakage que controlar.

Después aplico `StandardScaler` y `OneHotEncoder`, que dejan 18 dimensiones, y un PCA reteniendo el 90% de varianza, lo cual deja 8 componentes. Clusterizo sobre PCA porque reduce ruido y acelera. La elección de $k$ no me la dieron los criterios automáticos: no hay un codo dramático (cosa típica con datos mixtos categórico/numéricos) y la silueta media baja suavemente, de 0,42 con $k = 2$ a 0,39 con $k = 3$ y a un valor mucho menor con $k = 4$. Me quedo con $k = 3$ como solución principal porque permite distinguir un tercer perfil interpretable sin perder mucha silueta, y dejo $k = 2$ como vista alternativa más gruesa. Quiero subrayar que $k = 3$ no se elige para imitar las tres clases de `objetivo`: esa comparación se hace después como validación a posteriori.

Para asegurarme de que los clusters no son un capricho del algoritmo, comparo KMeans con Ward jerárquico para el mismo $k = 3$. KMeans da silueta 0,39 y Ward 0,40, y el ARI entre las dos particiones es 0,89: en otras palabras, los clusters están en los datos, no en el método. La estabilidad por bootstrap también se porta bien: repito KMeans sobre 20 submuestras al 80% y comparo cada partición con la de referencia, obteniendo ARI medio 0,91, mínimo 0,77 y desviación estándar 0,10.

**Table 3:** Perfiles de los tres clusters: medias reales de variables clave.

| Variable | Cluster 0 | Cluster 1 | Cluster 2 |
|---|---|---|---|
| Tamaño ($n$) | 3289 | 856 | 279 |
| Nota media 1.er sem. | 12,7 | 1,9 | 12,7 |
| Nota media 2.º sem. | 12,6 | 0,5 | 12,7 |
| Asig. aprobadas 1.er sem. | 5,3 | 0,4 | 11,5 |
| Asig. aprobadas 2.º sem. | 5,1 | 0,1 | 9,9 |
| Edad al matricularse | 22,0 | 26,0 | 29,6 |
| Nota de admisión | 126,8 | 126,6 | 130,4 |
| % graduados | 59,3 | 8,9 | 64,9 |
| % abandonos | 20,0 | 82,4 | 20,8 |
| % matriculados | 20,6 | 8,8 | 14,3 |

La tabla 3 resume los tres perfiles. El *cluster 1* (n=856) es el de riesgo, con nota media casi 0 en los dos semestres, menos de media asignatura aprobada, edad algo mayor y un 82% de abandono. El *cluster 0* (el grande, n=3289) es de rendimiento medio-bueno, con unas 5 aprobadas por semestre y nota cercana a 12, y se gradúa el 59%. El *cluster 2* (n=279) es el más interesante: rendimiento muy alto con la peculiaridad de que la edad media es 29,6 años y aprueban casi todo lo que se matriculan (11,5 y 9,9 asignaturas por semestre). La lectura natural es que se trata de estudiantes mayores con motivación alta y mucha dedicación; es además el perfil que más se gradúa (65%).

Cuando comparo a posteriori con `objetivo`, el ARI sale 0,15. No reproducen la etiqueta real, pero sí capturan parte de la estructura: el cluster 1 está dominado por abandonos (82%) y los otros dos por graduados. Es lo esperable, porque el clustering describe perfiles globales, mientras que `objetivo` es un desenlace que depende del tiempo y no se puede reconstruir solo con medias de rendimiento. La visualización con t-SNE confirma esto: las zonas del mapa 2D se solapan parcialmente con los clusters de KMeans y con las clases reales, los abandonos se concentran en un lóbulo bastante claro y los graduados en otro, con matriculado esparcido entre ambos.

Probé también $k = 2$ por curiosidad: la silueta sube a 0,42, pero el tercer perfil (los mayores muy aplicados del cluster 2) se funde con el cluster grande y se pierde información interpretable. Eso me confirmó que $k = 3$ era mejor decisión para el análisis, aunque la silueta fuera ligeramente menor.

## 7 Interpretación crítica, limitaciones y riesgos

Lo primero que quiero subrayar es la coherencia entre las tres tareas. Las variables que más mandan en clasificación (`asignaturas_2sem_aprobadas`, `matricula_al_dia`, `asignaturas_1sem_aprobadas`, `nota_media_2sem`, `edad_al_matricularse`), las que mandan en regresión (`asignaturas_1sem_aprobadas`, `nota_media_1sem`, `asignaturas_1sem_evaluadas`, `matricula_al_dia`) y las que más diferencian los

clusters (las mismas de rendimiento, junto con la edad) coinciden bastante. Eso le da consistencia al análisis y me hace pensar que la señal es real, no un artefacto de un modelo concreto.

Hay que separar bien lo que estos modelos resuelven y lo que no. La clasificación da números muy buenos en parte porque se apoya en variables del 2.º semestre, así que es más diagnóstico al cierre del curso que alerta temprana. Si quisiera un sistema de detección a mitad del 1.er semestre tendría que reentrenar solo con variables anteriores a ese corte, y el F1 macro bajaría bastante. La regresión, por construcción, ya lo está haciendo así, y aun con esa restricción llega a $R^2 \sim 0{,}73$. Si metiera el 2.º semestre, ese $R^2$ subiría a $\sim 0{,}9$, pero habría dejado de ser una pregunta interesante.

También conviene insistir en que correlación no implica causalidad. Que `deudor=sí` se asocie con mayor abandono no significa que pagar la matrícula cause graduarse; es más probable que ambas cosas sean síntomas de una situación económica delicada. Lo mismo pasa con `matricula_al_dia`. Cualquier lectura en clave de "palanca actuable", como ofrecer becas o ampliar plazos de pago, tiene sentido como hipótesis pero requeriría un análisis causal específico que este proyecto no hace.

La clase "matriculado" es el cuello de botella del proyecto, y aparece como el caso más difícil en las tres tareas. Es la menos representada, la intermedia, y la que peor separa por construcción. Un F1 de 0,44 sobre matriculado no es del todo malo (el baseline para esa clase aislada estaría en torno a 0,30), pero deja claro que cualquier sistema de decisión que se construya encima tiene que asumir que las fronteras entre las tres clases no son nítidas.

Sobre los sesgos potenciales y el uso responsable, el EDA muestra diferencias claras en `objetivo` por género, nacionalidad y curso. Antes de desplegar un modelo así en una institución real habría que auditar el rendimiento estratificado por esos ejes (paridad demográfica, igualdad de oportunidades, tasas de falsos negativos por grupo), cosa que aquí no hago por alcance. Y un modelo que detecte alumnado en riesgo debería usarse solo para ofrecer apoyo, nunca como filtro de admisión o para asignación de recursos limitados, porque entonces estaría codificando desigualdades preexistentes en lugar de mitigarlas.

Por último, las limitaciones del propio estudio. Trabajo con un único dataset y un único periodo académico, así que no sé hasta qué punto los perfiles que encuentro generalizan a otros centros o a otras cohortes. La bimodalidad del target de regresión limita el tipo de modelo que se puede usar de forma limpia y, como ya he dicho, una regresión condicional en dos etapas habría sido más adecuada. Y los cursos con $n < 50$ tienen demasiado ruido para extraer conclusiones fuertes sobre ellos.

## 8 Conclusiones

Con los 37 predictores disponibles consigo clasificar la situación final del estudiante con F1 macro de 0,69, muy por encima del baseline trivial de 0,22, predecir la nota media del 2.º semestre con un 48% de reducción de RMSE usando solo información del 1.er semestre y variables de entrada, y obtener tres perfiles de estudiantes que aguantan tanto el cambio de algoritmo como el submuestreo.

La lectura más clara que dejan los tres modelos es que el rendimiento del 1.er semestre, la nota de admisión, la situación administrativa (matrícula al día, deuda) y la edad al matricularse son los factores con más señal. Las macroeconómicas casi no aportan a nivel individual.

Si tuviese que elegir una sola lectura del proyecto, no sería la métrica del modelo ganador sino el hecho de que las mismas cuatro o cinco variables aparecen arriba en las tres tareas independientes. Eso es lo que da confianza de que la señal es real y no un artefacto del método. Un modelo así debería usarse exclusivamente como herramienta interna de apoyo al alumnado en riesgo, con auditorías periódicas de sesgos y con la cabeza fría a la hora de traducir correlaciones en intervenciones.

### Uso de inteligencia artificial

He utilizado herramientas de IA generativa (ChatGPT y Claude) como apoyo durante la elaboración del proyecto, en las siguientes tareas concretas. Para la edición y formato: paso de la memoria a la plantilla NeurIPS en LaTeX (estructura del `.tex`, tablas con `booktabs`, ajustes de `geometry` y `titlesec`) y formato del README en Markdown. Para consultas técnicas puntuales: parámetros concretos de `scikit-learn`, sintaxis de `ColumnTransformer`, integración de `imblearn.Pipeline` con `SMOTENC` y modo correcto de llamar a `shap.TreeExplainer`

para clasificadores multiclase. Y para detectar erratas y sugerir reformulaciones de pasajes torpes.

El análisis exploratorio, la elección de modelos, las decisiones metodológicas (qué variables excluir por leakage, por qué F1 macro frente a *accuracy*, por qué $k = 3$ en clustering), la interpretación de resultados y las conclusiones son trabajo propio. Las herramientas de IA no han generado los notebooks ni el contenido analítico de esta memoria: han actuado como apoyo de edición y aclaración técnica, equivalentes a una consulta a documentación o a un compañero.